REVISIÓN CRÍTICA

DE LA HIPÓTESIS AL MANUSCRITO: ¿PUEDE UNA INTELIGENCIA ARTIFICIAL CONDUCIR UNA INVESTIGACIÓN COMPUTACIONAL COMPLETA?

Evidencia experimental, autonomía real, riesgos epistemológicos y criterios de gobernanza para los agentes científicos

Afiliación: Independiente

ORCID: https://orcid.org/0000-0002-4817-1963 **Correo:** jose.tlc.16@hotmail.com

Autor: José Andrés Viñán Carrasco

Cómo citar este artículo:

Viñán Carrasco JA. De la hipótesis al manuscrito: ¿puede una inteligencia artificial conducir una investigación computacional completa? Evidencia experimental, autonomía real, riesgos epistemológicos y criterios de gobernanza para los agentes científicos. Zenodo; 2026. doi:10.5281/zenodo.21755496.

RESUMEN

La automatización científica basada en modelos fundacionales está evolucionando desde herramientas aisladas hacia flujos coordinados capaces de proponer ideas, consultar literatura, programar, ejecutar experimentos, interpretar resultados, redactar manuscritos y simular la revisión por pares. Esta revisión narrativa crítica examina 20 publicaciones relevantes sobre agentes científicos, laboratorios autónomos, descubrimiento asistido por inteligencia artificial, escritura académica e integridad de la investigación, tomando como eje la arquitectura The AI Scientist. La evidencia disponible muestra que una proporción considerable del trabajo empírico computacional puede organizarse con intervención humana limitada; sin embargo, no demuestra autonomía científica plena. La selección humana de resultados, el reducido número de manuscritos sometidos a evaluación externa, la naturaleza exclusivamente digital de los experimentos y la diferencia entre predecir decisiones editoriales y verificar conocimiento impiden equiparar productividad documental con comprensión científica. Se propone considerar estos sistemas como infraestructuras de investigación supervisada y se formula un marco de control basado en trazabilidad, separación de responsabilidades, auditoría del código, replicación independiente, validación estadística y límites institucionales. En disciplinas clínicas, su incorporación debe restringirse inicialmente al apoyo técnico y documental, sin sustituir el juicio profesional ni la responsabilidad del investigador.

Palabras clave: inteligencia artificial; agentes autónomos; automatización científica; revisión por pares; reproducibilidad; integridad de la investigación.

ABSTRACT

Scientific automation based on foundation models is evolving from isolated tools into coordinated workflows capable of proposing ideas, retrieving literature, writing and debugging code, running experiments, interpreting results, drafting manuscripts and emulating peer review. This critical narrative review examines 20 relevant publications on scientific agents, autonomous laboratories, AI-assisted discovery, academic writing and research integrity, using The AI Scientist as its central case. Current evidence indicates that a substantial share of computational empirical work can be orchestrated with limited direct human intervention; however, it does not establish full scientific autonomy. Human selection of outputs, the small number of manuscripts subjected to external review, the exclusively digital nature of the experiments and the gap between predicting editorial decisions and validating knowledge prevent document productivity from being equated with scientific understanding. These systems are therefore better regarded as supervised research infrastructures. A governance framework is proposed based on traceability, separation of responsibilities, code auditing, independent replication, statistical validation and institutional limits. In clinical disciplines, initial deployment should remain restricted to technical and documentary support and must not replace professional judgement or researcher accountability.

Keywords: artificial intelligence; autonomous agents; scientific automation; peer review; reproducibility; research integrity.

1. INTRODUCCIÓN

Automatizar actividades científicas no es una aspiración reciente. Antes de los actuales modelos de lenguaje, los sistemas computacionales ya podían demostrar teoremas, explorar reacciones químicas, reconocer patrones en datos experimentales y proponer leyes matemáticas. La diferencia contemporánea reside en la integración: una misma arquitectura puede combinar lectura, razonamiento lingüístico, programación, acceso a herramientas y producción documental dentro de un flujo prolongado [2-12,20].

Esta integración ha dado origen al concepto de agente científico. No se trata de un modelo que responde una pregunta aislada, sino de un sistema que conserva memoria operativa, selecciona acciones, consulta fuentes, modifica código, ejecuta pruebas y utiliza los resultados de una etapa para decidir la siguiente. El trabajo publicado por Lu y colaboradores constituye la demostración más completa de este enfoque en investigación de aprendizaje automático [1].

El alcance debe delimitarse cuidadosamente. Los experimentos estudiados ocurren en computadoras y no requieren pacientes, muestras biológicas ni manipulación física. Por ello, el éxito en ciencia computacional no puede trasladarse sin validación adicional a medicina, odontología, biología experimental o ciencias sociales.

2. PROPÓSITO Y ENFOQUE ANALÍTICO

El propósito de esta revisión es explicar cómo se organiza la automatización de extremo a extremo en investigación computacional, valorar la solidez de la evidencia presentada y distinguir cuatro conceptos que suelen confundirse: automatización de tareas, autonomía para decidir, calidad del conocimiento producido y responsabilidad institucional.

La revisión toma como eje el estudio publicado en Nature en 2026 y lo contrasta con antecedentes de científicos robot, laboratorios autónomos, agentes químicos y sistemas de descubrimiento asistido por inteligencia artificial [2-13,19,20]. Las interpretaciones sobre gobernanza y aplicación clínica corresponden al análisis crítico desarrollado en este manuscrito.

3. MÉTODO DE BÚSQUEDA Y SELECCIÓN DOCUMENTAL

Se realizó una revisión narrativa crítica y dirigida, no sistemática. La base documental quedó constituida por 20 publicaciones comprendidas entre 2004 y 2026, seleccionadas por su relación directa con automatización de la investigación, agentes científicos, laboratorios autónomos, descubrimiento asistido por inteligencia artificial, modelos fundacionales en medicina, escritura científica e integridad académica. Se priorizaron artículos originales, revisiones y perspectivas publicados en revistas científicas reconocidas, además de una versión preliminar solo cuando aportaba contexto histórico; en la versión final se evitó duplicar un mismo proyecto mediante la sustitución del preprint de The AI Scientist por una perspectiva independiente sobre comprensión científica mediada por inteligencia artificial.

La identificación y comprobación bibliográfica se realizó mediante búsquedas dirigidas por título, autor, tema y DOI en registros de editoriales, bases académicas y repositorios científicos. Se incluyeron trabajos con datos bibliográficos verificables y pertinencia conceptual para al menos uno de los ejes del análisis. Se excluyeron noticias, entradas de opinión sin revisión académica, documentos sin autoría o procedencia identificable y referencias duplicadas. La síntesis fue cualitativa: se contrastaron arquitectura, grado de autonomía, validación externa, reproducibilidad, riesgos de integridad y requisitos de supervisión. Debido a su carácter narrativo y a la heterogeneidad de las fuentes, no se efectuó metaanálisis ni evaluación cuantitativa del riesgo de sesgo.

4. DEL MODELO AISLADO AL SISTEMA CIENTÍFICO

La plataforma integra modelos de lenguaje, motores de búsqueda académica, herramientas de ingeniería de software, intérpretes de Python, almacenamiento de resultados, modelos multimodales y un evaluador de manuscritos. En conjunto, estos componentes forman una cadena con seis funciones: plantear, contrastar, experimentar, valorar, comunicar y revisar.

La capacidad no emerge de un único modelo omnisciente. Surge de la coordinación entre módulos especializados y de la posibilidad de volver sobre pasos anteriores cuando aparecen errores. Esta propiedad convierte al flujo de investigación en un problema de ingeniería de procesos.

5. DOS FORMAS DE AUTOMATIZACIÓN

5.1. Modo guiado por un punto de partida

En la modalidad guiada, el sistema recibe código funcional elaborado por humanos. Ese código define el ambiente, los datos y una ejecución de referencia. El agente propone variaciones, formula hipótesis acotadas y desarrolla una agenda breve de experimentos. La ventaja es la estabilidad; la desventaja es que el espacio de investigación ya está fuertemente condicionado.

Las ideas se almacenan con título, justificación, hipótesis, plan y autoevaluaciones de interés, novedad y viabilidad. La consulta a Semantic Scholar ayuda a descartar similitudes evidentes, aunque no sustituye una revisión sistemática de la literatura ni garantiza novedad conceptual.

5.2. Modo abierto y búsqueda en árbol

La modalidad abierta reduce la dependencia de una plantilla inicial y reparte responsabilidades entre modelos de razonamiento, generación de código, visión y evaluación. La exploración se representa como un árbol: cada nodo conserva plan, programa, métricas, errores, figuras y críticas. Los nodos prometedores se expanden; los defectuosos se corrigen o abandonan.

El proceso avanza por viabilidad, ajuste de hiperparámetros, agenda principal y ablaciones. La selección del mejor nodo al finalizar cada fase permite reutilizar aprendizaje acumulado, pero también introduce un objetivo interno que puede favorecer aquello que el evaluador automatizado puntúa mejor.

6. MEMORIA, DEPURACIÓN Y PRODUCCIÓN DEL MANUSCRITO

Cuando un experimento falla, el sistema registra la traza, solicita una modificación y vuelve a ejecutar. Las observaciones y resultados se incorporan a un diario experimental que funciona como memoria externa. Sin este registro, el agente tendería a repetir errores o perder decisiones tomadas en etapas anteriores.

La redacción se realiza sobre una estructura LaTeX. El agente genera secciones, figuras y pies, incorpora referencias y corrige problemas de compilación. Un modelo multimodal inspecciona gráficos y busca incoherencias de ejes, leyendas o correspondencia entre texto y figura. Esta revisión mejora la presentación, pero no prueba que el diseño experimental o la implementación sean correctos.

7. REVISIÓN AUTOMATIZADA: UTILIDAD Y LÍMITES

El revisor automático aplica criterios inspirados en NeurIPS y produce síntesis, fortalezas, debilidades, preguntas, preocupaciones éticas y puntuaciones. Para reducir variación se generan varias revisiones y una metarrevisión final.

Su desempeño se evaluó contra decisiones públicas de conferencias. La exactitud balanceada fue cercana a 0,69 para artículos de 2017–2024 y alrededor de 0,66 para el conjunto de 2025 [1]. Estos valores muestran capacidad para imitar patrones de decisión editorial, no para establecer verdad, reproducibilidad o relevancia científica.

8. QUÉ DEMOSTRÓ LA EVALUACIÓN HUMANA

Tres manuscritos del modo abierto fueron enviados, con autorización y protocolo ético, a un taller de ICLR 2025. Uno recibió calificaciones de 6, 7 y 6 y habría superado la primera fase de revisión; los otros dos quedaron por debajo del umbral [1].

La conclusión válida es una prueba de posibilidad. No puede estimarse una tasa general de éxito porque los trabajos fueron seleccionados previamente, el número fue mínimo y el taller aceptaba cerca del 70% de las presentaciones. Los investigadores también señalaron que ninguno alcanzaba el estándar de la conferencia principal.

9. AUTONOMÍA REAL: UNA LECTURA POR CAPAS

La automatización fue alta dentro del flujo: el sistema produjo código, resultados, figuras, texto y revisiones. La autonomía de objetivos fue mucho menor, porque personas definieron el dominio, los modelos, las instrucciones, el presupuesto, el evento y los criterios de selección.

La autonomía institucional fue inexistente. El agente no puede aprobar un protocolo, responder por una falsificación, asumir obligaciones legales ni autorizar una publicación. Tampoco se demostró autonomía epistemológica, entendida como comprensión profunda, juicio causal general o capacidad para reconocer por sí misma la importancia histórica de una idea. La literatura sobre comprensión científica mediada por IA refuerza la necesidad de distinguir predicción, explicación y entendimiento [13].

10. FORTALEZAS DE LA DEMOSTRACIÓN

- Integra en una sola arquitectura actividades que antes se evaluaban por separado.
- Incluye una prueba externa dentro de un proceso real de revisión por pares.
- Incorpora replicaciones, ablaciones y agregación de resultados en la modalidad abierta.
- Evalúa artículos posteriores al corte de conocimiento para reducir contaminación.
- Reconoce fallos y no afirma haber alcanzado calidad estable de conferencia principal.
- Publica componentes de código y documenta el protocolo ético de envío y retirada.

11. LIMITACIONES QUE CONDICIONAN LA INTERPRETACIÓN

11.1. Muestra reducida

Solo tres manuscritos preseleccionados llegaron a revisión humana; sin el número total de intentos no puede calcularse productividad útil.

11.2. Umbral editorial favorable

El taller tuvo una aceptación mucho mayor que la conferencia principal, por lo que superar ese umbral no representa la máxima exigencia del campo.

11.3. Selección humana

Personas eligieron las salidas más prometedoras y verificaron adecuación temática, funcionamiento y formato antes del envío.

11.4. Evaluación indirecta

La concordancia con decisiones humanas mide similitud editorial y puede omitir errores de causalidad, datos, código o referencias.

11.5. Dominio digital

La extrapolación a laboratorios físicos o entornos clínicos exige capas adicionales de seguridad, regulación y validación.

12. RIESGOS PARA LA CALIDAD Y LA INTEGRIDAD

La reducción del costo de producir manuscritos puede saturar la revisión por pares. Un gran volumen de trabajos plausibles, aun cuando la mayoría sea mediocre, aumenta la carga editorial y facilita que errores sutiles atraviesen filtros superficiales. La literatura reciente también advierte sobre problemas de fabricación de contenido, atribución, transparencia y responsabilidad en la escritura científica asistida por modelos generativos [14-17].

También existe riesgo de contaminación acumulativa: textos defectuosos pueden ser citados por otros artículos o incorporados en futuros corpus de entrenamiento. El problema deja de ser una alucinación aislada y se convierte en una red de afirmaciones que se respaldan entre sí sin una base empírica sólida.

Cuando la recompensa del sistema es una puntuación de aceptación, puede optimizar señales de estilo, estructura o novedad aparente. La gobernanza debe impedir que el objetivo operativo de publicar sustituya al objetivo científico de producir conocimiento confiable.

13. IMPLICACIONES PARA MEDICINA Y ODONTOLOGÍA

En áreas clínicas, los agentes deberían introducirse como copilotos. Pueden priorizar literatura, estructurar preguntas, preparar borradores de protocolos, generar código estadístico, revisar la coherencia entre tablas y texto o detectar referencias incompletas. Los modelos fundacionales médicos amplían estas posibilidades, pero requieren validación específica para cada contexto de uso [18].

No deben completar datos ausentes, decidir tratamientos, interpretar imágenes diagnósticas sin validación, reclutar participantes, modificar bases originales ni enviar resultados sin revisión profesional. La incertidumbre clínica, la seguridad del paciente y las obligaciones regulatorias requieren supervisión humana directa [18,20].

14. MARCO PROPUESTO DE GOBERNANZA

La utilidad de los agentes científicos dependerá menos de una declaración genérica de supervisión y más de controles verificables. Se proponen diez requisitos mínimos para proyectos que empleen automatización avanzada.

1. Registrar instrucciones, versiones de modelos, herramientas, datos, código y decisiones.
2. Separar las funciones de generación, crítica y validación humana independiente.
3. Conservar resultados positivos, negativos y rutas descartadas.
4. Proteger los datos originales mediante copias versionadas y controles de acceso.
5. Replicar externamente los hallazgos centrales antes de formular afirmaciones fuertes.
6. Verificar manualmente cada referencia y su correspondencia con el texto.
7. Auditar supuestos estadísticos, comparaciones múltiples, tamaños de efecto e incertidumbre.
8. Documentar las funciones y responsabilidades de cada participante del proyecto.

9. Aplicar revisión ética reforzada cuando intervengan personas, animales o datos sensibles.
10. Establecer límites de ejecución y envío para evitar producción masiva no supervisada.

15. NIVELES DE IMPLEMENTACIÓN INSTITUCIONAL

La Tabla 1 organiza cinco grados de implementación institucional y un nivel basal sin IA generativa. Cada nivel vincula el uso predominante con el control mínimo requerido para preservar la trazabilidad, la calidad metodológica y la responsabilidad humana.

Tabla 1. Niveles de implementación institucional y controles mínimos

Nivel	Uso predominante y control requerido
0	Sin IA generativa. Control: prácticas científicas convencionales.
1	Búsqueda, traducción y apoyo de estilo. Control: verificación documental completa.
2	Código y análisis asistidos. Control: revisión humana integral del procedimiento y los resultados.
3	Agente experimental en entorno cerrado. Control: auditoría técnica, registro de decisiones y trazabilidad.
4	Flujo casi autónomo. Control: validación externa reforzada antes de comunicar o publicar resultados.
5	Autonomía abierta. No recomendable actualmente para investigación clínica ni publicación sin regulación específica.

16. AGENDA DE INVESTIGACIÓN

- Evaluar series amplias de proyectos sin selección previa para estimar tasas reales de éxito.
- Comparar agentes y equipos humanos bajo presupuestos equivalentes de tiempo y cómputo.
- Medir reproducibilidad externa y corrección del código, no solo aceptación editorial.
- Desarrollar pruebas para citas incorrectas, análisis inválidos y conclusiones exageradas.
- Examinar si las propuestas representan conocimiento nuevo o recombinaciones sofisticadas.
- Crear estándares de conservación de registros, responsabilidad y evaluación institucional.
- Probar aplicaciones clínicas primero en simulación y entornos controlados.

17. DISCUSIÓN

El aporte central de esta línea de trabajo es mostrar que una parte de la investigación computacional puede describirse mediante estados, herramientas, memoria, criterios de transición y evaluadores. Esto desplaza parte del esfuerzo intelectual hacia el diseño del sistema, la formulación del objetivo y la auditoría de sus decisiones.

La consecuencia más importante es la necesidad de separar velocidad de validez. Un manuscrito coherente puede contener código equivocado, comparaciones oportunistas o referencias que no sostienen las afirmaciones. La evaluación futura deberá examinar artefactos, registros y reproducibilidad, no únicamente la prosa final.

La opción más defendible en el corto plazo es un modelo híbrido: agentes para exploración, repetición y control de consistencia; investigadores humanos para significado, selección de problemas, ética, interpretación y responsabilidad.

18. CONCLUSIONES

La automatización integral de determinadas investigaciones computacionales en aprendizaje automático ya es técnicamente posible bajo condiciones delimitadas. Los agentes pueden enlazar ideación, búsqueda, programación, experimentación, análisis, escritura y revisión dentro de un mismo flujo.

La evidencia disponible no demuestra la sustitución general del investigador. El rendimiento fue desigual, la muestra de evaluación humana fue reducida, existió selección manual y el entorno se restringió a experimentos digitales. Predecir una decisión editorial tampoco equivale a verificar una afirmación científica.

El desarrollo responsable exige trazabilidad, auditoría del código, validación estadística, replicación externa y control de referencias. En ciencias clínicas, los agentes deben limitarse a funciones supervisadas. El progreso debe medirse por reproducibilidad, utilidad y seguridad.

DECLARACIONES

Identificador persistente: https://doi.org/10.5281/zenodo.21755496

Versión del documento: 1.0 | **Fecha del documento:** agosto de 2026

Contribución del autor: José Andrés Viñán Carrasco realizó la conceptualización, revisión crítica, organización e interpretación del contenido y aprobó la versión final del manuscrito.

Disponibilidad de datos: No se generaron conjuntos de datos nuevos. Las fuentes examinadas se encuentran citadas en la lista de referencias.

Aprobación ética: No aplica, por tratarse de una revisión crítica que no involucró participantes, animales ni datos clínicos identificables.

Conflictos de interés: El autor declara no tener conflictos de interés relacionados con este manuscrito.

Financiamiento: El autor declara que este trabajo no recibió financiamiento externo específico.

REFERENCIAS

1. Lu C, Lu C, Lange RT, Yamada Y, Hu S, Foerster J, Ha D, Clune J. Towards end-to-end automation of AI research. Nature. 2026;651:914–919. doi:10.1038/s41586-026-10265-5.
2. Boiko DA, MacKnight R, Kline B, Gomes G. Autonomous chemical research with large language models. Nature. 2023;624:570-578. doi:10.1038/s41586-023-06792-0.
3. King RD, Whelan KE, Jones FM, Reiser PGK, Bryant CH, Muggleton SH, Kell DB, Oliver SG. Functional genomic hypothesis generation and experimentation by a robot scientist. Nature. 2004;427:247-252. doi:10.1038/nature02236.
4. King RD, Rowland J, Oliver SG, Young M, Aubrey W, Byrne E, et al. The automation of science. Science. 2009;324:85-89. doi:10.1126/science.1165620.
5. Schmidt M, Lipson H. Distilling free-form natural laws from experimental data. Science. 2009;324:81-85. doi:10.1126/science.1165893.
6. Jumper J, Evans R, Pritzel A, Green T, Figurnov M, Ronneberger O, et al. Highly accurate protein structure prediction with AlphaFold. Nature. 2021;596:583-589. doi:10.1038/s41586-021-03819-2.
7. Merchant A, Batzner S, Schoenholz SS, Aykol M, Cheon G, Cubuk ED. Scaling deep learning for materials discovery. Nature. 2023;624:80-85. doi:10.1038/s41586-023-06735-9.
8. Burger B, Maffettone PM, Gusev VV, Aitchison CM, Bai Y, Wang X, et al. A mobile robotic chemist. Nature. 2020;583:237-241. doi:10.1038/s41586-020-2442-2.
9. Häse F, Roch LM, Aspuru-Guzik A. Next-generation experimentation with self-driving laboratories. Trends Chem. 2019;1:282-291. doi:10.1016/j.trechm.2019.02.007.
10. Stach EA, DeCost BL, Kusne AG, Hattrick-Simpers J, Brown KA, Reyes KG, et al. Autonomous experimentation systems for materials development: A community perspective. Matter. 2021;4:2702-2726. doi:10.1016/j.matt.2021.06.036.
11. Coley CW, Thomas DA, Lummiss JAM, Jaworski JN, Breen CP, Schultz V, et al. A robotic platform for flow synthesis of organic compounds informed by AI planning. Science. 2019;365:eaax1566. doi:10.1126/science.aax1566.
12. Bran AM, Cox S, Schilter O, Baldassari C, White AD, Schwaller P. Augmenting large language models with chemistry tools. Nat Mach Intell. 2024;6:525-535. doi:10.1038/s42256-024-00832-8.
13. Krenn M, Pollice R, Guo SY, Aldeghi M, Cervera-Lierta A, Friederich P, et al. On scientific understanding with artificial intelligence. Nat Rev Phys. 2022;4:761-769. doi:10.1038/s42254-022-00518-3.
14. Gao CA, Howard FM, Markov NS, Dyer EC, Ramesh S, Luo Y, Pearson AT. Comparing scientific abstracts generated by ChatGPT to real abstracts with detectors and blinded human reviewers. NPJ Digit Med. 2023;6:75. doi:10.1038/s41746-023-00819-6.
15. Salvagno M, Taccone FS, Gerli AG. Can artificial intelligence help for scientific writing? Crit Care. 2023;27:75. doi:10.1186/s13054-023-04380-2.
16. van Dis EAM, Bollen J, Zuidema W, van Rooij R, Bockting CL. ChatGPT: Five priorities for research. Nature. 2023;614:224-226. doi:10.1038/d41586-023-00288-7.
17. Currie GM. Academic integrity and artificial intelligence: Is ChatGPT hype, hero or heresy? Semin Nucl Med. 2023;53:719-730. doi:10.1053/j.semnuclmed.2023.04.008.
18. Moor M, Banerjee O, Abad ZSH, Krumholz HM, Leskovec J, Topol EJ, Rajpurkar P. Foundation models for generalist medical artificial intelligence. Nature. 2023;616:259-265. doi:10.1038/s41586-023-05881-4.
19. MacKnight R, Boiko DA, Regio JE, Gallegos LC, Neukomm TA, Gomes G, et al. Rethinking chemical research in the age of large language models. Nat Comput Sci. 2025;5:715-726. doi:10.1038/s43588-025-00811-y.
20. Wang H, Fu T, Du Y, Gao W, Huang K, Liu Z, et al. Scientific discovery in the age of artificial intelligence. Nature. 2023;620:47-60. doi:10.1038/s41586-023-06221-2.